
title: "HunyuanImage-2.1 顯卡相容性測試報告"

subtitle: "AMD 與 NVIDIA GPU 效能比較"

author: "測試者"

date: "2025年10月21日"

geometry:

- margin=1in
- a4paper documentclass: article fontsize: 11pt CJKmainfont: "Noto Sans CJK TC" header-includes: |\usepackage{fancyhdr} \pagestyle{fancy} \usepackage{xcolor} \usepackage{booktabs}

HunyuanImage-2.1 顯卡相容性測試報告

測試概述

本文件記錄了 **Tencent HunyuanImage-2.1** 在不同 GPU 型號上的測試結果，重點關注 2048×2048 影像生成的顯存需求與效能表現。

測試配置

共通設定

- 模型: hunyuanimage-v2.1
- 解析度: 2048×2048 (1:1 長寬比)

- 推理步數: 50
- 精度: FP8 (use_fp8=True)
- Refiner: 關閉 (use_refiner=False)
- Reprompt: 關閉 (use_reprompt=False)
- 環境變數: `PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True`

測試提示詞

A cute, cartoon-style anthropomorphic penguin plush toy with fluffy fur, standing in a painting studio, wearing a red knitted scarf and a red beret with the word "Asrock" on it, holding a paintbrush with a focused expression as it paints an oil painting of the Mona Lisa, rendered in a photorealistic photographic style.

測試結果

✅ AMD Radeon AI PRO R9700 (32GB 顯存)

規格	數值
GPU 型號	AMD Radeon AI PRO R9700
架構	gfx1201
總顯存	32 GB
框架	ROCm 6.4.2 + PyTorch 2.6.0
狀態	✅ 成功
生成時間 (Stage-1)	每張約 5 分鐘

規格	數值
顯存峰值 (Stage-1)	約 20.2 GB
Refiner 支援	✔ 可正常運行 Stage-1 + Refiner
備註	32GB 顯存足以運行完整兩階段流程

額外觀察

- FlashAttention (Triton 後端) 在 ROCm 上正常運作
- 整個生成過程記憶體配置穩定
- 32GB 顯存可成功運行 Stage-1 + Refiner 完整流程
- Stage-1 使用約 20.2 GB，Refiner 額外需求約 8-10 GB

✔ NVIDIA GeForce RTX 4090 (24GB 顯存)

規格	數值
GPU 型號	NVIDIA GeForce RTX 4090
總顯存	24 GB
框架	CUDA 13.0 + PyTorch (25.01 容器版本)
狀態	✔ 成功
生成時間	約 1 分 57 秒 (50 步)
每步耗時	約 2.34 秒/步
顯存峰值	20.16 GB (Refiner 載入前)
備註	Stage-1 運行穩定，效能優異

詳細執行資訊

Prompt: A cute, cartoon-style anthropomorphic penguin plush toy
with fluffy fur, standing in a painting studio, wearing
a red knitted scarf and a red beret with the word
"Asrock" on it, holding a paintbrush with a focused
expression as it paints an oil painting of the Mona Lisa,
rendered in a photorealistic photographic style.

Guidance Scale: 3.5

CFG Mode: MIX_mode_0

Shift: 5

Seed: 649151

Use byT5: True

Image Size: 2048 x 2048

Sampling Steps: 50

Denoising Progress: 100% (50/50 steps, 2.34s/step)

額外觀察

- 生成速度比 AMD R9700 快約 2.5 倍（1分57秒 vs 5分鐘）
 - 顯存使用量相近（20.16 GB vs 20.2 GB）
 - byT5 文字編碼器已啟用
 - 採用 MIX_mode_0 CFG 模式
 - **Refiner 載入失敗**：Stage-1 完成後嘗試載入 Refiner 時被系統 Killed，確認 24GB 顯存不足以運行完整的兩階段流程
-

✖ NVIDIA GeForce RTX 5060 Ti (16GB 顯存)

規格	數值
GPU 型號	NVIDIA GeForce RTX 5060 Ti
總顯存	16 GB (15.47 GiB 可用)
框架	CUDA + PyTorch
狀態	✖ 失敗 (OOM)
錯誤類型	<code>torch.OutOfMemoryError</code>
失敗時顯存	已使用 15.08 GiB，僅剩 73.94 MiB 可用

錯誤詳情

第一次測試:

`torch.OutOfMemoryError: CUDA out of memory. Tried to allocate 130.00 MiB. GPU 0 has a total capacity of 15.47 GiB of which 73.94 MiB is free. Including non-PyTorch memory, this process has 15.08 GiB memory in use. Of the allocated memory 14.95 GiB is allocated by PyTorch, and 4.83 MiB is reserved by PyTorch but unallocated.`

第二次測試:

`torch.OutOfMemoryError: CUDA out of memory. Tried to allocate 130.00 MiB. GPU 0 has a total capacity of 15.47 GiB of which 132.62 MiB is free. Including non-PyTorch memory, this process has 14.96 GiB memory in use. Of the allocated memory 14.82 GiB is allocated by PyTorch, and 14.33 MiB is reserved by PyTorch but unallocated.`

分析

第一次測試:

- **PyTorch 配置:** 14.95 GiB
- **保留但未配置:** 4.83 MiB
- **剩餘顯存:** 73.94 MiB

第二次測試:

- **PyTorch 配置:** 14.82 GiB
- **保留但未配置:** 14.33 MiB
- **剩餘顯存:** 132.62 MiB

結論:

- 兩次測試皆在嘗試配置額外 130 MiB 時失敗
- 即使開啟 `expandable_segments:True`，仍無法釋放足夠空間
- 碎片化程度極低（保留但未配置記憶體 <15 MiB）
- **16GB 顯存確實不足以進行 2048×2048 生成**，即使使用 FP8 優化

比較總結

GPU 型號	顯存	狀態	時間 (2048×2048)	顯存峰值	備註
NVIDIA RTX 4090	24 GB	✔ 成功	約 1 分 57 秒	20.16 GB	效能最佳

GPU 型號	顯存	狀態	時間 (2048×2048)	顯存峰值	備註
AMD R9700	24 GB	✔ 成功	約 5 分鐘	20.2 GB	穩定，可運行 Stage-1
NVIDIA RTX 5060 Ti	16 GB	✘ OOM	N/A	N/A	顯存不足

效能分析

24GB 顯卡比較：

- RTX 4090 生成速度約為 R9700 的 2.5 倍
- 兩者顯存使用量相近（~20.2 GB）
- RTX 4090 每步僅需 2.34 秒，R9700 每步約 6 秒

Refiner（Stage-2）實測結果：

- RTX 4090 (24GB)：Stage-1 完成後載入 Refiner 時被系統 Killed
- AMD R9700 (24GB)：未嘗試載入 Refiner（已知會超出顯存）
- 結論：24GB 顯存僅足夠運行 Stage-1，Refiner 需額外 4GB+ 顯存
- 實際 Refiner 需求：建議 28-32GB 顯存才能運行完整的兩階段流程

建議方案

針對 16GB 顯存 GPU（如 RTX 5060 Ti）

1. 使用蒸餾版模型

```
python
```

```
model_name = "hunyuanimage-v2.1-distilled"  
num_inference_steps = 8
```

- 顯存需求大幅降低
- 生成速度更快（1-2 分鐘）

2. 降低解析度

- 嘗試 1536×1536 或 1024×1024
- 後期使用超解析度模型放大

3. 啟用 CPU 卸載（若支援）

```
python
```

```
pipe.enable_model_cpu_offload()
```

4. 使用更低精度

- 確保啟用 FP8 或 FP16
- 檢查是否有額外的量化選項

針對 24GB+ 顯存 GPU（如 AMD R9700）

1. Stage-1 生成

- 2048×2048 生成穩定可靠
- 5 分鐘生成時間可接受

2. Refiner（Stage-2）考量

- 2K 解析度需要 >24GB 顯存
- 建議使用 32GB+ 顯存 GPU 才能運行完整流程
- 或使用較低解析度搭配 Refiner

顯存需求（估算）

配置	最低顯存	建議顯存
僅 Stage-1，2048×2048，FP8	20 GB	24 GB
Stage-1 + Refiner，2048×2048	28 GB	32 GB
蒸餾版，1536×1536	12 GB	16 GB
蒸餾版，2048×2048	14 GB	16 GB

結論

HunyuanImage-2.1 對高解析度生成有相當高的顯存需求：

-  **24GB 顯存**是 2K 生成的實際最低需求（僅 Stage-1）
-  **16GB 顯存**不足以進行標準 2048×2048 生成
-  建議 顯存少於 20GB 的 GPU 使用蒸餾版模型

AMD R9700（24GB）成功證明了該模型在正確設定 FlashAttention 的 ROCm 環境下可以高效運行，在相同顯存等級下達到與 NVIDIA GPU 相當的效能表現。

測試環境詳情

AMD R9700 環境

- **Docker 映像:** `rocm/pytorch:rocm6.4.2_ubuntu24.04_py3.12_pytorch_release_2.6.0`
- **ROCm 版本:** 6.4.2
- **PyTorch 版本:** 2.6.0
- **FlashAttention:** ROCm Triton 後端 (main_perf 分支)
- **Triton 版本:** 3.2.0

NVIDIA RTX 4090 環境

- **Docker 映像:** `nvcr.io/nvidia/pytorch:25.01-py3`
- **CUDA 版本:** 13.0
- **驅動程式版本:** 580.95.05
- **PyTorch 版本:** 容器內建版本 (2025.01)

NVIDIA RTX 5060 Ti 環境

- **Docker 映像:** `nvcr.io/nvidia/pytorch:25.01-py3`
 - **CUDA 版本:** 13.0
 - **驅動程式版本:** 580.95.05
 - **PyTorch 版本:** (容器內建版本)
-

測試日期: 2025年10月21日

測試者: (您的姓名/組織)